10. Regresión Lineal

Juan Bernal

2024-08-30

La recta de mejor ajuste (Primera entrega)

Analiza la base de datos de estatura y peso en México y obten el mejor modelo de regresión para esos datos.

```
M = read.csv("Estatura-peso_HyM.csv")
MM = subset(M,M$Sexo=="M")
MH = subset(M,M$Sexo=="H")
M1=data.frame(MH$Estatura,MH$Peso,MM$Estatura,MM$Peso)

head(M1)
```

```
##   MH.Estatura MH.Peso MM.Estatura MM.Peso
## 1        1.61   72.21        1.53   50.07
## 2        1.61   65.71        1.60   59.78
## 3        1.70   75.08        1.54   50.66
## 4        1.65   68.55        1.58   56.96
## 5        1.72   70.77        1.61   51.03
## 6        1.63   77.18        1.57   64.27
```

1. Obtén la matriz de correlación de los datos que se te proporcionan. Interpreta.

```
cor(M1,method = "pearson")
```

```
##              MH.Estatura     MH.Peso  MM.Estatura    MM.Peso
## MH.Estatura 1.0000000000 0.846834792 0.0005540612 0.04724872
## MH.Peso     0.8468347920 1.000000000 0.0035132246 0.02154907
## MM.Estatura 0.0005540612 0.003513225 1.0000000000 0.52449621
## MM.Peso     0.0472487231 0.021549075 0.5244962115 1.00000000
```

2. Obtén medidas (media, desviación estándar, etc) que te ayuden a analizar los datos.

```
n=4 #número de variables
d=matrix(NA,ncol=7,nrow=n)
for(i in 1:n){
  d[i,]<-c(as.numeric(summary(M1[,i])),sd(M1[ ,i]))
}
m=as.data.frame(d)

row.names(m)=c("H-Estatura","H-Peso","M-Estatura","M-Peso")
names(m)=c("Minimo","Q1","Mediana","Media","Q3","Máximo","Desv Est")
m
```

```
##            Minimo      Q1 Mediana     Media      Q3 Máximo   Desv Est
## H-Estatura   1.48  1.6100   1.650  1.653727  1.7000   1.80 0.06173088
## H-Peso      56.43 68.2575  72.975 72.857682 77.5225  90.49 6.90035408
## M-Estatura   1.44  1.5400   1.570  1.572955  1.6100   1.74 0.05036758
## M-Peso      37.39 49.3550  54.485 55.083409 59.7950  80.87 7.79278074
```

```
boxplot(M$Estatura~M$Sexo, ylab="Estatura", xlab="", col=c("blue","pink"), names=c("Hombres", "Mujeres"), main="Estatura")
```

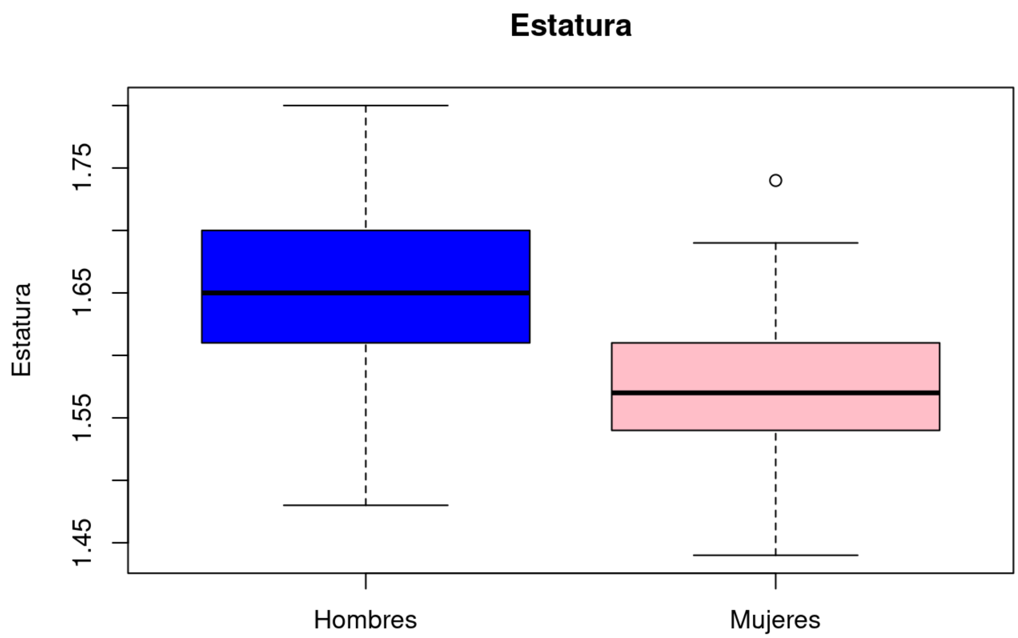


```
boxplot(M$Peso~M$Sexo, ylab="Peso",xlab="", names=c("Hombres", "Mujeres"), col=c('blue',"pink"), main="Peso")
```

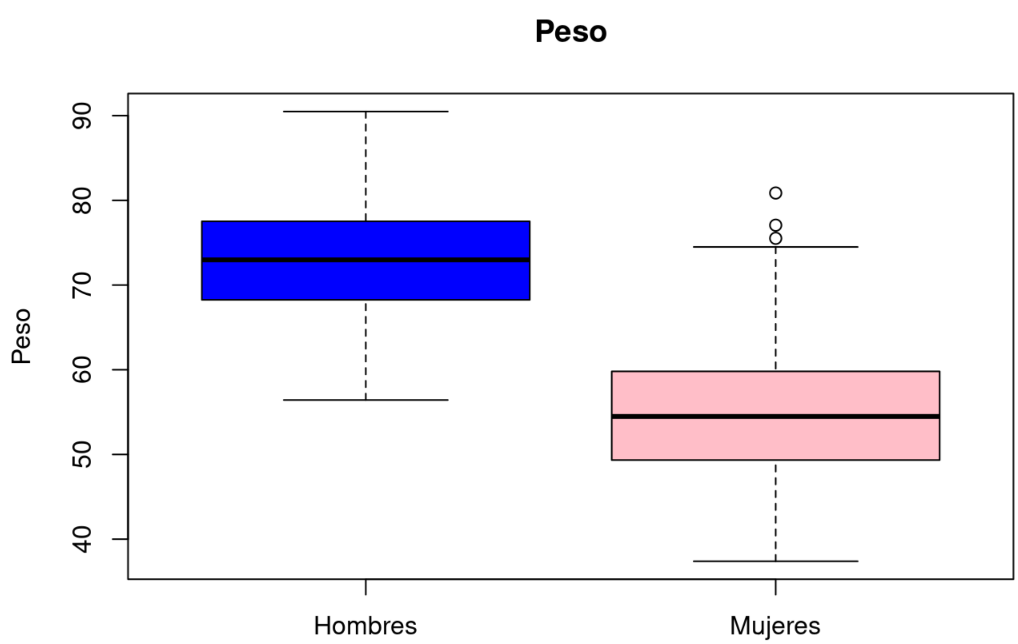

3. Encuentra la ecuación de regresión de mejor ajuste:

A. Realiza la regresión entre las variables involucradas

B. Verifica el modelo:

a. Verifica la significancia del modelo con un alfa de 0.03.

b. Verifica la significancia de β_i con un alfa de 0.03.

c. Verifica el porcentaje de variación explicada por el modelo.

4. Dibuja el diagrama de dispersión de los datos y la recta de mejor ajuste.

```
rl_h = lm(Peso~Estatura, MH) # Regresión lineal de la Estatura con base en el Peso de Hombres
summary(rl_h)
```

```
##
## Call:
## lm(formula = Peso ~ Estatura, data = MH)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -8.3881 -2.6073 -0.0665  2.4421 11.1883
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -83.685      6.663  -12.56   <2e-16 ***
## Estatura      94.660      4.027   23.51   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 3.678 on 218 degrees of freedom
## Multiple R-squared:  0.7171, Adjusted R-squared:  0.7158
## F-statistic: 552.7 on 1 and 218 DF,  p-value: < 2.2e-16
```

Hipótesis:

- $H_0 : \beta_1 = 0$
- $H_1 : \beta_1 \neq 0$

Este modelo con solo hombres, demuestra que la estatura es significante para el cálculo del peso, pues es menor a un nivel de 0.03 de confianza.

Modelo Hombres:

- $E_H = -83.685 + 94.66Peso$

```
plot(MH$Estatura, MH$Peso, col = "#00BFFF", main = "Peso Vs Estatura \n Hombres", ylab = "Peso", xlab = "Estatura", pch = 1
9)
abline(rl_h, col = "red", lwd = 1.6)
```

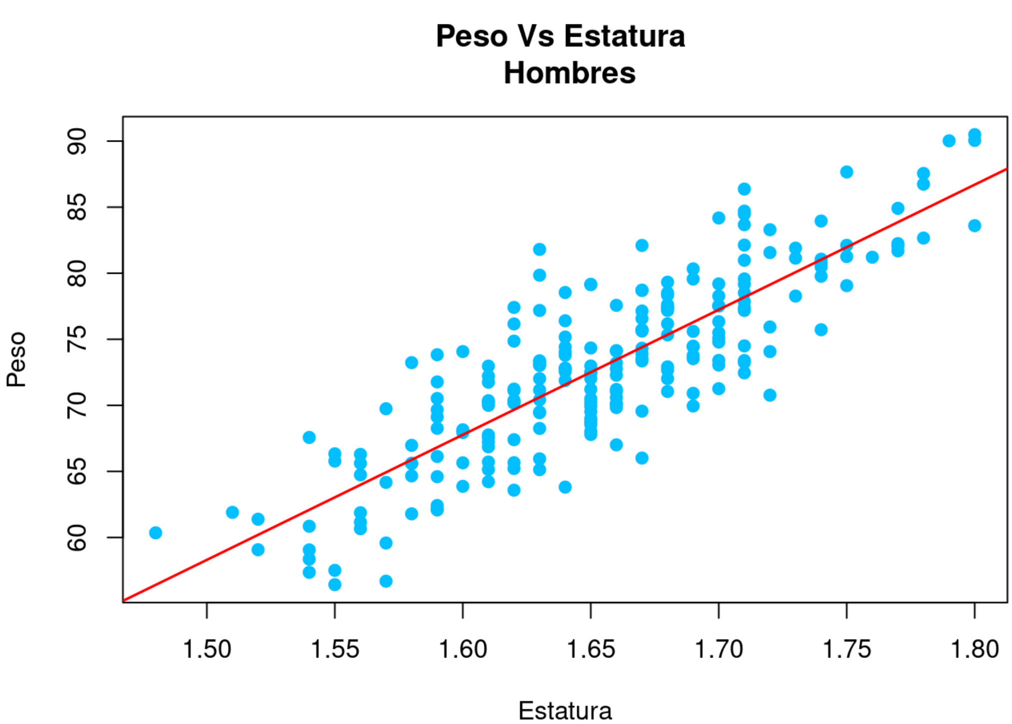

```
rl_m = lm(Peso~Estatura, MM) # Regresión lineal de la Estatura con base en el Peso de Hombres
summary(rl_m)
```

```
##
## Call:
## lm(formula = Peso ~ Estatura, data = MM)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -21.3256  -4.1942   0.4004   4.2724  17.9114
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -72.560     14.041  -5.168 5.34e-07 ***
## Estatura      81.149      8.922   9.096  < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 6.65 on 218 degrees of freedom
## Multiple R-squared:  0.2751, Adjusted R-squared:  0.2718
## F-statistic: 82.73 on 1 and 218 DF,  p-value: < 2.2e-16
```

Hipótesis:

- $H_0 : \beta_1 = 0$
- $H_1 : \beta_1 \neq 0$

Este modelo con solo mujeres, demuestra que la estatura es significante para el cálculo del peso, pues es menor a un nivel de 0.03 de confianza.

Modelo Mujeres:

- $E_M = -72.56 + 81.149Estatura$

```
plot(MM$Estatura, MM$Peso, col = "pink2", main = "Peso Vs Estatura \n Mujeres", ylab = "Peso", xlab = "Estatura", pch = 19)
abline(rl_m, col = "red", lwd = 1.6)
```

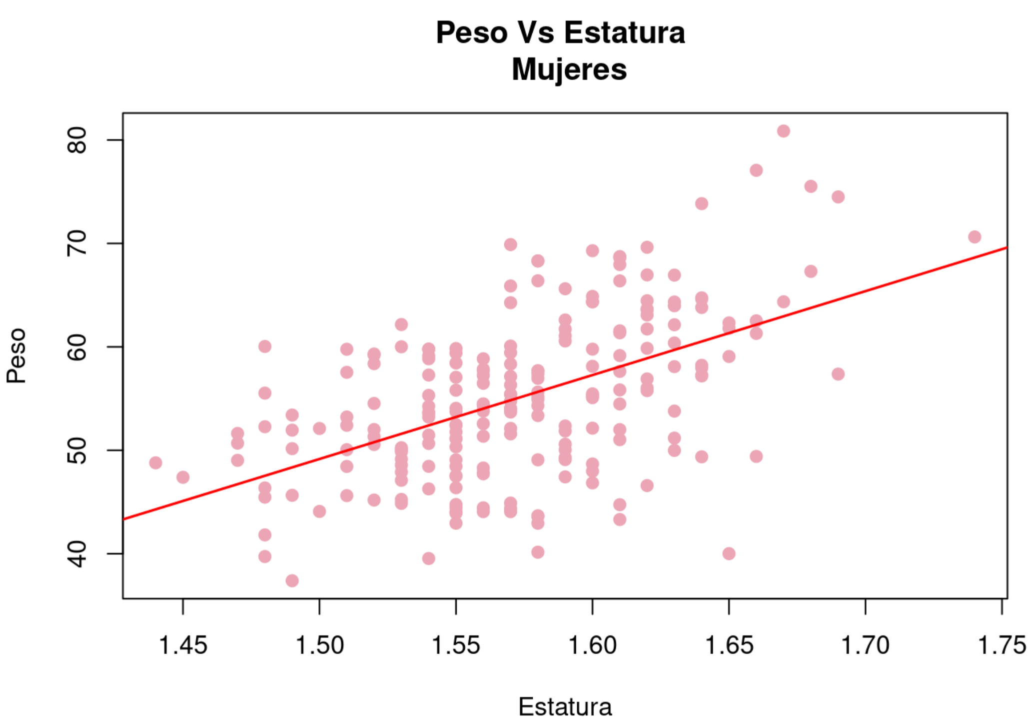


```
rl = lm(Peso~Estatura+Sexo, M)
summary(rl)
```

```
##
## Call:
## lm(formula = Peso ~ Estatura + Sexo, data = M)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -21.9505  -3.2491   0.0489   3.2880  17.1243
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept) -74.7546     7.5555  -9.894   <2e-16 ***
## Estatura     89.2604     4.5635  19.560   <2e-16 ***
## SexoM       -10.5645     0.6317 -16.724   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 5.381 on 437 degrees of freedom
## Multiple R-squared:  0.7837, Adjusted R-squared:  0.7827
## F-statistic: 791.5 on 2 and 437 DF,  p-value: < 2.2e-16
```

El modelo que considera la estatura y sexo para predecir el peso de la persona es significativo, pues su p-value es menor a un 0.03 de significancia.

- E = -74.7546 + 89.2604 Estatura - 10.5645 SexoM

```
b0 = rl$coefficients[1] # Beta 0
b1 = rl$coefficients[2] # Beta 1
b2 = rl$coefficients[3] # Beta 2

Ym = function(x){b0 + b1*x + b2} # Lleva Beta 2, porque las mujeres se representan con un 1
Yh = function(x){b0 + b1*x} # No lleva Beta 2, porque los hombres se representan con un 0

colores = c('lightblue', 'pink2')
plot(M$Estatura, M$Peso, col = colores[factor(M$Sexo)], pch = 19, ylab = "Peso", xlab = "Estatura", main = "Relación Peso vs
Estatura~Sexo")
x = seq(1.40, 1.80, 0.01)
lines(x, Ym(x), col = 'pink2', lwd=2)
lines(x, Yh(x), col = 'lightblue', lwd=2)
```

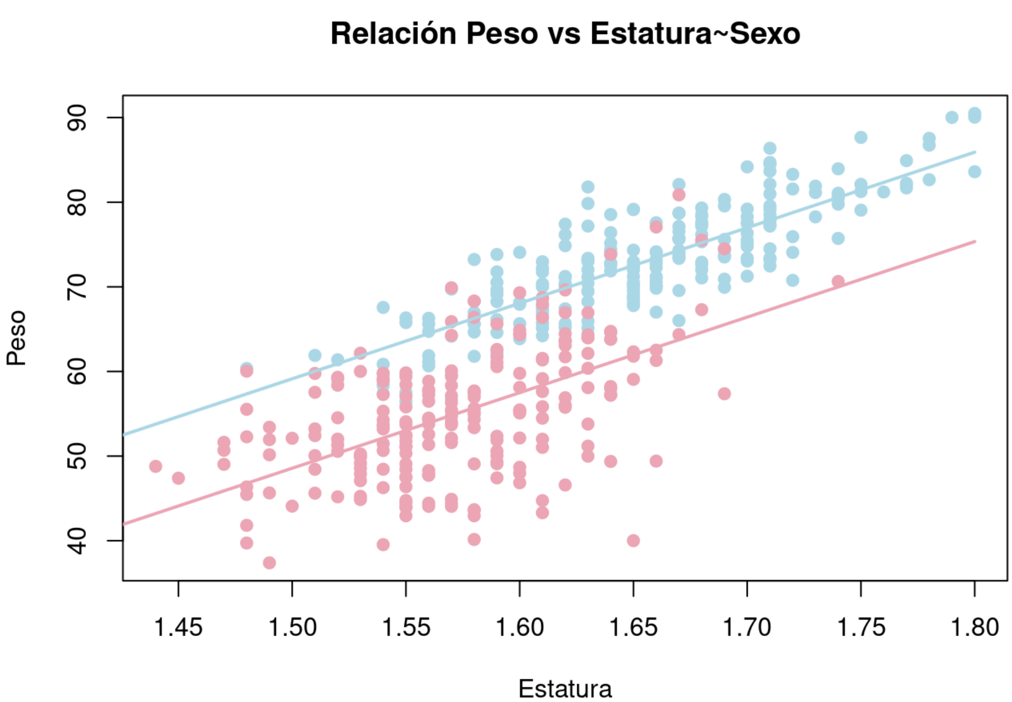

El modelo con solo hojmbres explica un 71.71% de la variación, el de solo mujeres explica un 27.51% y el modelo que considera ambos sexos explica un 78.37% de la variación.

5. Interpreta en el contexto del problema cada uno de los análisis que hiciste.

Los análisis anteriores demuestran la importancia de la estatura y sexo de la persona para poder predecir su peso. Además, se hace un análisis por separado de hombres y mujeres para demostrar que existe una diferencia significativa entre el modelo que define la estatura de un hombre y la de una mujer.

6. Interpreta en el contexto del problema:

A. ¿Qué información proporciona $\hat{\beta}_0$ sobre la relación entre la estatura y el peso de hombres y mujeres?

El coeficiente $\hat{\beta}_0$ es el intercepto del modelo. Representa el valor esperado del peso cuando la estatura y la variable de sexo (SexoM) son iguales a cero.

B. ¿Cómo interpretas $\hat{\beta}_1$ en la relación entre la estatura y el peso de hombres y mujeres?

Indica que la estatura tiene un efecto positivo significativo en el peso, con un incremento en la estatura resultando en un incremento en el peso, independientemente del sexo.